

Restaurant Recommendation System

Nguyễn Thị Hoàng Anh, Nguyễn Hà Dung, Huỳnh Văn Tín

Faculty of Information Science and Engineering, University of Information Technology,

Ho Chi Minh City, Vietnam

Vietnam National University, Ho Chi Minh City, Vietnam

{20520134, 20520165}@gm.uit.edu.vn

tinhv@uit.edu.vn

Abstract

Hiện nay, cùng với sự phát triển vượt bậc của Internet mà người dùng có thể tìm bất kỳ thông tin nào mọi lúc. Mọi người ngày càng dựa vào đánh giá của người khác để quyết định nên mua món đồ nào, xem phim nào, đọc sách gì và ăn ở đâu. Nhưng ngược lại ta thấy được một mặt trái của hiện trạng này đó là sự quá tải thông tin. Các lựa chọn dường như không giới hạn làm cho người dùng thường gặp khó khăn trong việc đưa ra những lựa chọn sáng suốt đáp ứng mong muốn và nhu cầu cá nhân của họ. Đặc biệt hơn là trong lĩnh vực ăn uống khi số lượng và loại hình ăn uống ngày càng đa dạng và phát triển. Một giải pháp cho vấn đề này là hệ thống đề xuất cung cấp các đề xuất chính xác và được cá nhân hóa. Điều này sẽ làm giảm đáng kể công sức và thời gian cần thiết để khám phá những nhà hàng mới. Từ mục đích đó, nhóm xây dựng một hệ khuyến nghị nhà hàng (*Restaurants Recommendation System*) sử dụng các phương pháp khuyến nghị khác nhau. Trong phạm vi đồ án, nhóm sử dụng dữ liệu từ Bộ dữ liệu Yelp và sử dụng hai độ đo HR và NDCG đánh giá các phương pháp *Collaborative Filtering*, *Content-based Filtering* và *Knowledge-based* cụ thể là mô hình *Knowledge-aware Coupled Graph Neural Network* (KCGN). Nhóm thu được kết quả tốt nhất là 0.772 HR@10 và 0.507 NDCG@10 qua phương pháp Knowledge-based, tốt hơn vượt bậc so với hai phương pháp truyền thống còn lại.

1 Giới thiệu

Hệ khuyến nghị (*Recommender System – RS*) đã xuất hiện từ giữa những năm 90 của thế kỷ 20 để giải quyết vấn đề quá tải thông tin (Park et al., 2012). Do sự bùng nổ nhanh chóng của thông tin nên các hệ thống khuyến nghị ngày nay càng trở nên phổ biến và được sử dụng rộng rãi trong công việc nghiên cứu nhằm cung cấp cho người dùng các đề xuất được cá nhân hóa (*Personalization techniques*) (Gao et al., 2010) dựa trên sở thích và mối quan

tâm trước đây của họ. Hệ thống đề xuất có thể áp dụng trong nhiều lĩnh vực như thương mại điện tử (Castro-Schez et al., 2011; Huang et al., 2007), âm nhạc (Lee et al., 2010; Nanopoulos et al., 2010; Tan et al., 2011), phim ảnh (Barragáns-Martínez et al., 2010; Yu et al., 2006), ... và đặc biệt là trong lĩnh vực Nhà hàng. Hệ thống khuyến nghị nhà hàng là một dịch vụ rất phổ biến với độ chính xác và độ tinh tế không ngừng tăng lên mỗi ngày. Với sự ra đời của Internet và Smartphone, mọi người tiêu dùng đều có thể tiếp cận điều này. Người dùng có thể có được bất kỳ thông tin nào họ muốn bất cứ khi nào và bất cứ nơi nào bằng cách sử dụng điện thoại di động của họ.

Trong những năm gần đây, các phương pháp khuyến nghị đã trải qua quá trình nghiên cứu, phát triển lâu dài và có nhiều cách phân loại cũng như tiếp cận RS đã được nghiên cứu (Bobadilla et al., 2013; Park et al., 2012; Sharma et al., 2021). Việc phân loại hệ thống RS có thể dựa trên số lượng người dùng được đề xuất (Li et al., 2023), có thể phân thành hai loại chính: hệ khuyến nghị cá nhân (*Personalized Recommender System*) và hệ khuyến nghị nhóm (*Group Recommender System*). Hệ thống được cá nhân hóa thiết kế để dự đoán mục tiếp theo cho từng người dùng dựa trên sở thích và hành vi trước đây của họ, trong khi hệ thống đề xuất nhóm xem xét sở thích chung của một nhóm người dùng để đưa ra đề xuất giúp giảm bớt xung đột trong nhóm. Hệ thống đề xuất được cá nhân hóa là loại được nghiên cứu và nghiên cứu rộng rãi nhất, tập trung vào việc cá nhân hóa các đề xuất theo sở thích của từng người dùng.

Theo xu hướng này, đồ án tập trung vào việc tạo ra một hệ thống khuyến nghị nhà có khả năng đề xuất chính xác và được cá nhân hóa. Bên cạnh đó thực nghiệm ba phương pháp tiếp cận là *Collaborative Filtering*, *Content-based* và *Knowledge-based* cụ thể là *Knowledge-aware Coupled Graph Neural Network* (KCGN).

Phần còn lại của báo cáo theo bố cục sau. Phần

2 trình bày tổng quan tài liệu. Tiếp theo, bộ dữ liệu và phương pháp xử lý dữ liệu sẽ được mô tả ở Phần 3. Các phương pháp khuyến nghị đề xuất được trình bày ở Phần 4. Phần 5 trình bày các thực nghiệm và kết quả. Cuối cùng, kết luận được nêu trong Phần 6.

2 Các công trình liên quan

Các hệ thống đề xuất thường nhắm mục tiêu đến các cá nhân và sử dụng các kỹ thuật lọc cộng tác và đề xuất dựa trên nội dung dựa trên lịch sử xem, mua hoặc xếp hạng của cá nhân đó. Hệ khuyến nghị là một xu hướng nghiên cứu được phát triển từ lâu, do đó tùy vào phương pháp tiếp cận mà hệ khuyến nghị được phân loại khác nhau. Các nghiên cứu trước đây đã phân loại hệ khuyến nghị được cá nhân hóa thành các dạng chính sau: lọc cộng tác (*Collaborative Filtering*), dựa trên nội dung (*Content-based*), dựa trên nhân khẩu (*Demographic-based*), dựa trên kiến thức (*Knowledge-based*), dựa trên cộng đồng (*Community-based*) và kết hợp (*Hybrid*).

Trong lọc cộng tác (*Collaborative Filtering - CF*), thành phần cốt lõi là thiết kế cơ chế dự đoán tùy chọn dựa trên các nhóm người dùng hoặc mục tương tự (Hartanto and Utama, 2020; Asani et al., 2021; Roy et al., 2018; Park et al., 2008). CF dựa trên ý tưởng rằng những người dùng có sở thích tương tự về các nhà hàng sẽ có sở thích tương tự trong tương lai. Các hệ thống này phân tích các tương tác trong quá khứ giữa người dùng và nhà hàng, chẳng hạn như lịch sử xếp hạng, để xác định các mẫu và đưa ra đề xuất. Bên cạnh đó, khuyến nghị dựa trên nội dung (*Content-based - CB*) là phương pháp sử dụng sự giống nhau giữa các item, trong trường hợp này là nhà hàng, để đề xuất các yếu tố liên quan theo sở thích của người dùng cụ thể mà không xem xét thông tin từ những người dùng khác (Ali et al., 2018; Son and Kim, 2017; Vanetti et al., 2011). CB thường được sử dụng để tạo hệ thống đề xuất dựa trên đặc điểm và sở thích cụ thể của người dùng, tạo ra các đề xuất chính xác mà không cần xem xét xếp hạng và dự đoán của người dùng khác. Với các loại RS này, việc tích hợp nguồn tri thức bên ngoài có thể cung cấp thêm thông tin về ngữ cảnh hoặc cá nhân hóa người dùng và các item, điều này đặc biệt hữu ích để cải thiện độ chính xác và hiệu suất của RS.

Trong vài năm qua, đã có nhiều nghiên cứu kết hợp biểu đồ tri thức (*Knowledge Graph - KG*) vào việc xây dựng tính năng học tập cho hệ khuyến nghị (Le et al., 2023). Các phương pháp đề xuất

dựa trên KG trước đây phụ thuộc vào tính năng thủ công và yêu cầu tính toán rộng về việc biểu diễn thực thể/quan hệ. Như nghiên cứu của (Wu et al., 2021) đã sử dụng mạng lưới thần kinh đồ thị (GNN) để nắm bắt các tương tác phong phú và thông tin bổ trợ trong KG. Bằng cách này, thông tin bổ trợ có thể được khai thác để làm phong phú thêm cách thể hiện của người dùng, thực thể và các mối quan hệ, chẳng hạn như các tương tác bậc cao (Wang et al., 2019d,b,c), quan hệ người dùng cụ thể (Wang et al., 2019a; Cao et al., 2019; Zhou et al., 2020), ... Năm 2021, (Huang et al., 2021) đã đề xuất một mô hình Mạng thần kinh đồ thị kết hợp nhận biết kiến thức (*Knowledge-aware Coupled Graph Neural Network*) cho khuyến nghị xã hội để cùng đưa kiến thức phụ thuộc lẫn nhau giữa các item và người dùng vào khung đề xuất. Mô hình cho phép mã hóa mối quan hệ giữa người dùng và vật phẩm bậc cao bằng cách khai thác thông tin lẫn nhau để nhận biết cấu trúc biểu đồ toàn cầu. Ngoài ra, KCGN còn có khả năng nắm bắt các mẫu tương tác linh hoạt giữa item và người dùng.

Lấy cảm hứng từ nghiên cứu (Huang et al., 2021), đồ án hướng đến xây dựng một hệ khuyến nghị cá nhân hóa tích hợp các thông tin bổ trợ để đề xuất. Từ đó, nhóm so sánh hiệu suất của mô hình KCGN so với hai phương pháp khuyến nghị cơ bản đã đề cập là *Collaborative Filtering* và *Content-based*.

3 Dữ liệu

3.1 Nguồn dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu có tên là *Yelp*¹ đến từ *Yelp Challenge* do tính sẵn có và chất lượng dữ liệu đại diện của nó. *Yelp Challenge* là một thử thách nhằm mục đích đạt được những hiểu biết sâu sắc và sáng tạo về hành vi, sở thích của người dùng và xu hướng thực phẩm bằng cách sử dụng dữ liệu được cung cấp. Hình 1 bên dưới cung cấp cái nhìn tổng quan về bộ dữ liệu *Yelp* và bộ dữ liệu gồm 5 file được miêu tả ở bảng 1




Figure 1: Tổng quan bộ dữ liệu *Yelp*

¹<https://www.yelp.com/dataset>

business.json	id, name, address, city, state, GPS coordinates, star rating, review counts, is_open, categories (e.g. "Restaurants", "Spa"), attributes (e.g. "WiFi")
review.json	review id, user id, business id, stars, review text, date, votes received from other users (useful, funny, or cool)
user.json	user id, name, review count, friends, compliments received
tip.json	Number check-ins for every hour and day of the week
checkin.json	Tip text, compliments received (e.g. "likes")

Table 1: Contents of Yelp Data Files

3.2 Tiền xử lý dữ liệu

Quy trình xử lý dữ liệu được thực hiện qua 4 giai đoạn: Data Pre-processing, Data Cleansing, Data Selection và Data Creation. Quá trình được mô tả qua hình 5.

3.2.1 Data Pre-processing

Bộ dữ liệu *Yelp* bao gồm dữ liệu về 150,346 doanh nghiệp ở Hoa Kỳ trên tất cả các lĩnh vực kinh doanh như dịch vụ, khách sạn, ăn uống, ... Từ đó, đầu tiên nhóm xử lý dữ liệu về item (*business.json*) chỉ chọn ra dữ liệu về doanh nghiệp có thuộc tính là "Restaurants" trong bộ dữ liệu.

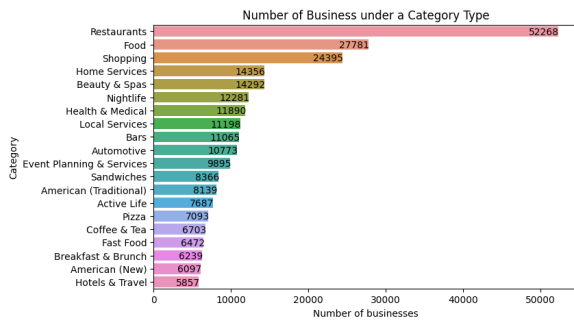


Figure 2: Mô tả thuộc tính các doanh nghiệp trong Bộ dữ liệu Yelp

Sau đó, để phù hợp với thực tế ta chỉ chọn các nhà hàng hiện đang có trạng thái mở "is_open" trong dữ liệu.

Thống kê các loại nhà hàng ta được một số lượng thuộc tính lớn (khoảng 678) và chứa nhiều thuộc tính phân bố rất ít. Do đó, nhóm chọn 100 thuộc tính "category" của nhà hàng là các phân loại chiếm đa số khi phân tích thể hiện ở hình 4 và loại bỏ các sample thuộc tính còn lại.

3.2.2 Data Cleansing

Sau khi tiền xử lý dữ liệu, nhóm tiến hành phân tích và loại bỏ các giá trị thiếu (missing values). Tiếp theo, nhóm sẽ chỉ giữ lại các thuộc tính sẽ




Figure 3: Mô tả thuộc tính các doanh nghiệp hiện mở trong Bộ dữ liệu Yelp

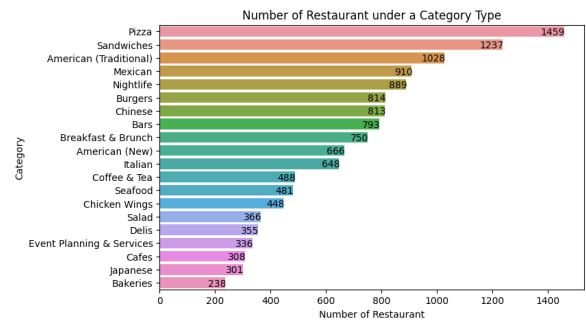


Figure 4: Mô tả thuộc tính các nhà hàng trong Bộ dữ liệu Yelp

sử dụng và xóa các thuộc tính không sử dụng như coordinates, post_code, is_open, ...

3.2.3 Data Selection

- **Restaurant:** Chỉ giữ lại các nhà hàng có trên 2 lượt đánh giá ("review_count" > 2)
- **Review:** Từ dữ liệu nhà hàng đã được xử lý, nhóm lọc ra những đánh giá về tất cả các nhà hàng đó từ dữ liệu *review.json* để thu được dữ liệu *review*.
- **User:** Từ "user_id" những đánh giá thu được tiến hành lọc ra thông tin người dùng từ *user.json*. Các user được giữ lại phải thỏa mãn yêu cầu có trên 2 bạn ("n_friends" > 2)

3.2.4 Data Creation

- **Category:** từ dữ liệu *restaurant* vì mục đích tạo ra content cho item ở mục 4.2.1 ở đây là nhà hàng, nhóm sẽ thống kê thuộc tính "categories" (phân loại nhà hàng theo thuộc tính như Fast Food, Pizza, ...) và "attributes" (Các đặc trưng yếu tố như Wifi, Alcohol, Parking, ...) và sử dụng phương pháp one-hot encoding mã hóa các giá trị của hai thuộc tính trên.

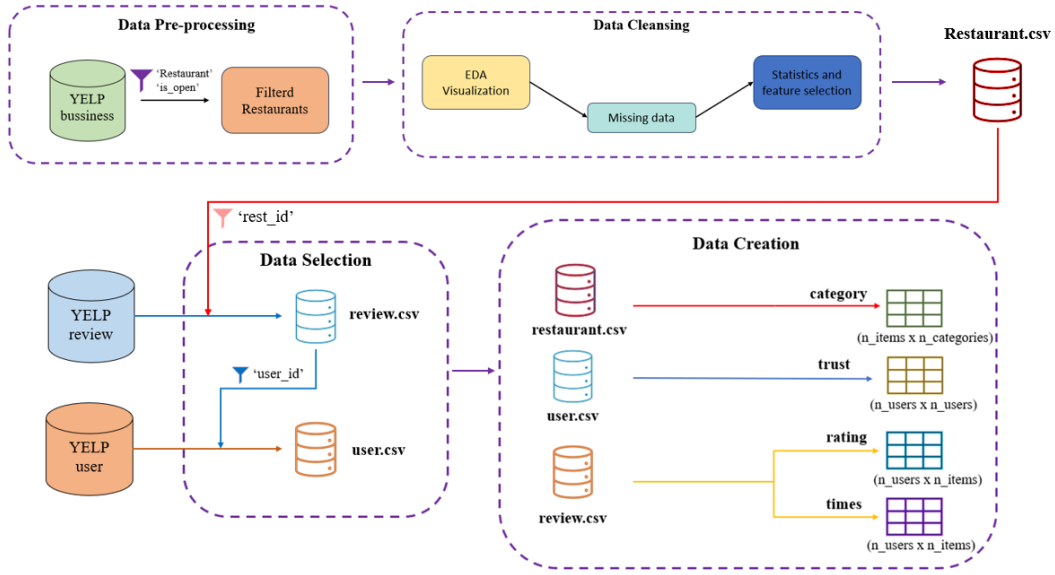


Figure 5: Quy trình xử lý dữ liệu Yelp

- **Rating:** từ dữ liệu *review* đã xử lý, tạo ma trận rating với *user_id* và *bussiness_id* với giá trị là giá trị rating mà người dùng đánh giá nhà hàng
- **Times:** từ dữ liệu *review* đã xử lý, tạo ma trận times với *user_id* và *bussiness_id* với giá trị là thời gian mà người dùng đánh giá nhà hàng ở dạng timestamp.
- **Trust:** từ dữ liệu *user* tạo ma trận quan hệ nhị phân giữa các user. Nếu hai user là bạn sẽ có giá trị 1, ngược lại là 0

3.3 Mô tả dữ liệu

Bảng 2 sau thống kê các bộ dữ liệu với Yelp là bộ dữ liệu gốc do Yelp công bố. Bên cạnh đó, với mục đích so sánh hiệu quả của mô hình trong đề án với bài báo gốc, Yelp (KCGN) là bộ dữ liệu bài báo (Huang et al., 2021) sử dụng. Cuối cùng, Yelp Restaurant là bộ dữ liệu nhà hàng cuối cùng sau quá trình xử lý đã ở phần 3.

Dataset	Yelp	Yelp (KCGN)	Yelp Restaurant
# of Users	1,987,897	43,043	6,385
# of Items	150,346	66,576	7,464
# of Interactions	6,990,280	283,512	44,336

Table 2: Thống kê bộ dữ liệu

4 Thực nghiệm

4.1 Cài đặt

4.1.1 Bài toán khuyến nghị item tuần tự

Trong phạm vi thực hiện đề án, mục tiêu của bài toán là tìm hiểu sở thích của người dùng dựa trên lịch sử tương tác với item của họ (đánh giá những nhà hàng họ đã ghé qua) và đề xuất các nhà hàng mới có liên quan dựa trên những thông tin đã tích lũy.

Gọi $U = \{u_1, u_2, \dots, u_I\}$ là tập hợp I user và $V = \{v_1, v_2, \dots, v_J\}$ là tập hợp J item (nhà hàng). Từ đó, chúng tôi định nghĩa chuỗi item (nhà hàng) mà user từng tương tác $s^u = (s_1^u, s_2^u, \dots, s_{l_{su}}^u) \in S$ với độ dài l_{su} và $s_j^u \in V$ với mỗi user u . Một mô hình khuyến nghị tuần tự $M : S \rightarrow R_n$, với R_n là tập hợp tất cả các hoán vị của danh sách các item index $(1, 2, \dots, |J|)$, có nhiệm vụ xếp hạng item tiếp theo đầu tiên trong danh sách index, dựa trên một chuỗi các hành vi trong quá khứ.

4.1.2 Chiến lược phân chia dữ liệu

Trong đề án, nhóm sẽ áp dụng phương pháp leave-one-out, vì đây là phương pháp phổ biến nhất được sử dụng trong các nghiên cứu về hệ khuyến nghị (Kang and McAuley, 2018; Sun et al., 2019). Đối với chiến lược chia dữ liệu này, với mỗi user, chúng tôi sẽ lấy tất cả item trong chuỗi hành vi trừ 2 item cuối phục vụ cho quá trình training $S_{train} = \{(s_1, s_2, \dots, s_{l_s-2}) | s \in S\}$. Mô hình được validate trên các item kế cuối s_{l_s-1} và test trên item cuối cùng (nhà hàng mà user đánh giá gần nhất) s_{l_s} .

4.1.3 Negative Sampling

Một vấn đề thường gặp phải khi huấn luyện và đánh giá mô hình khuyến nghị là số lượng item mà user đã từng tương tác là rất nhỏ so với số lượng item mà user chưa bao giờ tương tác. Điều này dẫn đến mô hình cần tốn rất nhiều tài nguyên để tính toán xác suất, xếp hạng và đưa ra khuyến nghị trên một tập lớn item chưa được tương tác. Để giảm thiểu chi phí tính toán, phương pháp Negative sampling được giới thiệu lần đầu bởi (Koren, 2008), giúp tính toán phân phối xác suất đầu ra và cập nhật nghiệm nhanh hơn.

Trong thực nghiệm trên tất cả các phương pháp, với mỗi user, chúng tôi sẽ chọn ngẫu nhiên 100 negative samples, tức là 100 nhà hàng mà user chưa đánh giá.

Quá trình phân chia dữ liệu và negative sampling được minh họa trong Hình 6

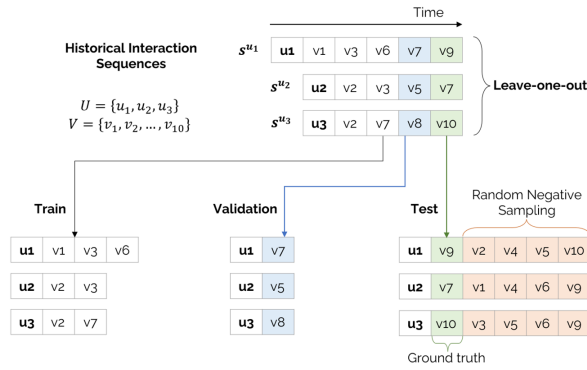


Figure 6: Mô tả thuộc tính chiến lược phân chia dữ liệu và negative sampling

4.1.4 Độ đo đánh giá

Chúng tôi sử dụng 2 độ đo phổ biến là Hit Ratio (HR) và Normalized Discounted Cumulative Gain (NDCG) (Shani and Gunawardana, 2011) để đánh giá hiệu suất của các phương pháp khuyến nghị.

Cho chuỗi s , item ground truth là $i_{gt} = s_{l_s-1}$ cho quá trình validation và $i_{gt} = s_{l_s}$ cho quá trình testing. Giá trị Hit Ratio tại vị trí k bằng 1 nếu item ground truth nằm trong $head(M(\hat{s}), k)$, với $\hat{s} = \{s_1, s_2, \dots, s_{l_s-2}\}$ cho validation và $\hat{s} = \{s_1, s_2, \dots, s_{l_s-1}\}$ cho testing, và $head(M(\hat{s}), k)$ là k vị trí đầu của danh sách khuyến nghị trả về từ mô hình M :

$$HR@k = \begin{cases} 1, & i_{gt} \in head(M(\hat{s}), k) \\ 0, & i_{gt} \notin head(M(\hat{s}), k) \end{cases} \quad (1)$$

Với NDCG, độ đo này sẽ quan tâm đến vị trí của item ground truth trong danh sách khuyến nghị. Cụ

thể, item ground truth nằm ở vị trí càng cao trong danh sách xếp hạng, thì giá trị NDCG càng lớn:

$$NDCG@k = \sum_{i=1}^k \delta(M(\hat{s})_i, i_{gt}) \frac{1}{\log(i+1)} \quad (2)$$

Trong đó, $M(\hat{s})_i$ là item ở vị trí thứ i trong danh sách khuyến nghị, $\delta(a, b) = 1$ nếu $a = b$ và ngược lại thì $\delta(a, b) = 0$

Trong đồ án này, nhóm đặt $k = 10$.

4.2 Phương pháp khuyến nghị

4.2.1 Content-based

Trong cách tiếp cận dựa trên lọc theo nội dung, hệ thống RS dựa trên lịch sử tương tác của người dùng u_I với item v_J và thông tin về thuộc tính của item (hoặc nội dung của đối tượng) để tìm ra các thuộc tính (đặc tính) có ảnh hưởng lớn đến đánh giá của người dùng đó. Đặc điểm sở thích của người dùng dựa trên đặc tính của nhà hàng v_J mà người dùng u_I yêu thích nhất được biểu diễn dưới dạng vector nhị phân $C = \{c_1, c_2, \dots, c_n\}$ với n là số lượng các thuộc tính của item, giá trị trọng số c_i mô tả sự thỏa điều kiện của thuộc tính. Như vậy thông tin về sở thích của người dùng và thông tin của nhà hàng được ánh xạ vào cùng không gian vector các thuộc tính của nhà hàng, sự phù hợp giữa sở thích của người dùng và nhà hàng được đo bằng góc lệch giữa 2 vector như minh họa Hình 7.




Figure 7: Ví dụ về cosine similarity (Rendle et al., 2012)

Để tính độ tương đồng giữa hai vector, ta sử dụng độ đo cosine theo công thức 3 với C_u là vector biểu diễn item đại diện cho sở thích của người dùng và

C_v đại diện cho item so sánh.

$$\begin{aligned} \text{sim}(C_u, C_v) &= \cos(C_u, C_v) = \frac{\vec{C_u} \cdot \vec{C_v}}{\|\vec{C_u}\| \cdot \|\vec{C_v}\|} \\ &= \frac{\sum_{i=1}^n C_{u,i} \cdot C_{v,i}}{\sqrt{\sum_{i=1}^n C_{u,i}^2} \cdot \sqrt{\sum_{i=1}^n C_{v,i}^2}} \end{aligned} \quad (3)$$

4.2.2 Item-based Collaborative Filtering

Thuật toán CF có thể đưa ra các đề xuất được cá nhân hóa bằng cách sử dụng các đánh giá từ những người dùng có cùng sở thích. Có hai phương pháp thường được sử dụng trong lọc cộng tác là: *memory-based* và *model-based*. Nhóm chọn tiếp cận theo phương pháp *memory-based* cụ thể là *Item-based CF*. Hệ thống RS khai phá những nhóm người dùng “tương tự” nhau dựa trên hành vi quá khứ của người dùng được ghi nhận trong ma trận tương tác item-user. Không như content-based sử dụng thuộc tính của nhà hàng làm đặc trưng, đối với Item-based CF hệ thống RS sẽ dựa trên giá trị xếp hạng của người dùng trong ma trận item-user. Để đề xuất item v_J cho người dùng u_I , sở thích của người dùng dựa trên đặc tính của nhà hàng v_J mà người dùng u_I yêu thích nhất được biểu diễn dưới dạng $I = \{r_{1,J}, r_{2,J}, \dots, r_{I,J}\}$ với I là số lượng user và $r_{I,J}$ là đánh giá của user với nhà hàng J . Đối với mỗi item là nhà hàng cũng được biểu diễn tương tự. Như vậy thông tin về sở thích của người dùng và thông tin của nhà hàng được ánh xạ vào cùng không gian vector đánh giá của user và được tính tương tự như công thức 3.

4.2.3 Knowledge-aware Coupled Graph Neural Network (KGCN)

Mô hình Knowledge-aware Coupled Graph Neural Network (KGCN) là một mô hình graph-based cho bài toán social recommendation được giới thiệu trong (Huang et al., 2021). Mô hình này được đề xuất để giải quyết ba vấn đề thường gặp trong một bài toán khuyến nghị:

- Phần lớn các mô hình chỉ xem xét mối quan hệ xã hội của người dùng mà bỏ qua sự phụ thuộc lẫn nhau giữa các item
- Hầu hết các giải pháp hiện có được thiết kế cho loại tương tác user-item đơn lẻ, khiến mô hình không thể nắm bắt được tính không đồng nhất trong tương tác.
- Bản chất biến đổi theo thời gian của tương tác giữa các user và item ít được chú trọng

Tác giả đề xuất mô hình KGCN gồm 2 module là Relation-aware Graph Neural Networks và Knowledge-aware Graph Neural Networks. Kiến trúc tổng quan của KGCN được minh họa trong Hình 8. Trong đó, relation-aware graph neural module có thể mã hóa các loại tương tác khác nhau giữa item và user, đồng thời kết hợp thêm thông tin thời gian để tăng cường việc học các mối quan hệ cộng tác để đưa ra đề xuất. Hơn nữa, tác giả đề xuất kiến trúc knowledge-aware graph neural có thể nắm bắt cả mối quan hệ user-user và item-item, đồng thời bảo toàn thông tin về các loại tương tác giữa item-user trong embedding của mỗi user và item. Để mô hình có thể nắm bắt được thông tin về các loại quan hệ item-item, user-user và user-item một cách hiệu quả, dữ liệu đầu vào của nó được biểu diễn như sau

Multi-typed Interaction Tensor \mathbf{X} . Một tensor 3 chiều $\mathbf{X} \in \mathbb{R}^{I \times J \times K}$ để biểu diễn các loại tương tác khác nhau giữa user và item, trong đó K là số lượng loại tương tác. Cụ thể, trong ngữ cảnh bài toán, loại tương tác ở đây là số sao mà user rate nhà hàng đó (Ví dụ: user u_1 rate 4 sao cho nhà hàng v_1 và 3 sao cho nhà hàng v_2 thì loại tương tác ở đây là 4 sao và 3 sao). Trong \mathbf{X} , thành phần $x_{i,j}^k = 1$ nếu user u_i đánh giá item v_j một giá trị k sao, còn $x_{i,j}^k = 0$ tức là u_i chưa tương tác với v_j . Để thể hiện sự biến động về thời gian của các loại tương tác, một temporal tensor $\mathbf{T} \in \mathbb{R}^{I \times J \times K}$ với kích thước bằng \mathbf{X} được định nghĩa để ghi lại thông tin timestamp ($t_{i,j}^k$) tương ứng với mỗi $x_{i,j}^k$, tức là thời điểm mỗi lần user đánh giá một nhà hàng.

User Social Graph G_u . $G_u = \{U, E_u\}$ biểu diễn mối quan hệ xã hội (cạnh E_u) giữa các user (node U). Tồn tại cạnh $e_{i,i'}$ giữa user u_i và $u_{i'}$ nếu hai user này kết bạn với nhau.

Item Inter-Dependency Graph G_v . Đồ thị $G_v = \{V, E_v\}$ được định nghĩa để biểu diễn sự phụ thuộc lẫn nhau giữa các item. Cụ thể, mỗi quan hệ item-item được biểu diễn bởi một triple $\{v_j, e_{j,j'}, v_{j'}\} | v_j, v_{j'} \in V\}$, trong đó, cạnh $e_{j,j'}$ mô tả mối quan hệ giữa item v_j và $v_{j'}$. Trong bối cảnh bài toán khuyến nghị nhà hàng, nếu 2 nhà hàng cùng thuộc 1 loại categories (món Pháp, món Trung Quốc,...) hoặc thuộc cùng 1 attribute (wifi, chỗ để xe,...), thì giữa chúng tồn tại cạnh $e_{j,j'}$.

Với **đầu vào** là các tensor \mathbf{X} , \mathbf{T} , đồ thị G_u và G_v , **đầu ra** của mô hình sẽ là một hàm dựa đoán cặp tương tác <user-item> sẽ xảy ra tiếp theo. Cụ thể, với mỗi user, mô hình sẽ dự đoán xác suất cho mỗi item trong danh sách đề cử. item có xác suất

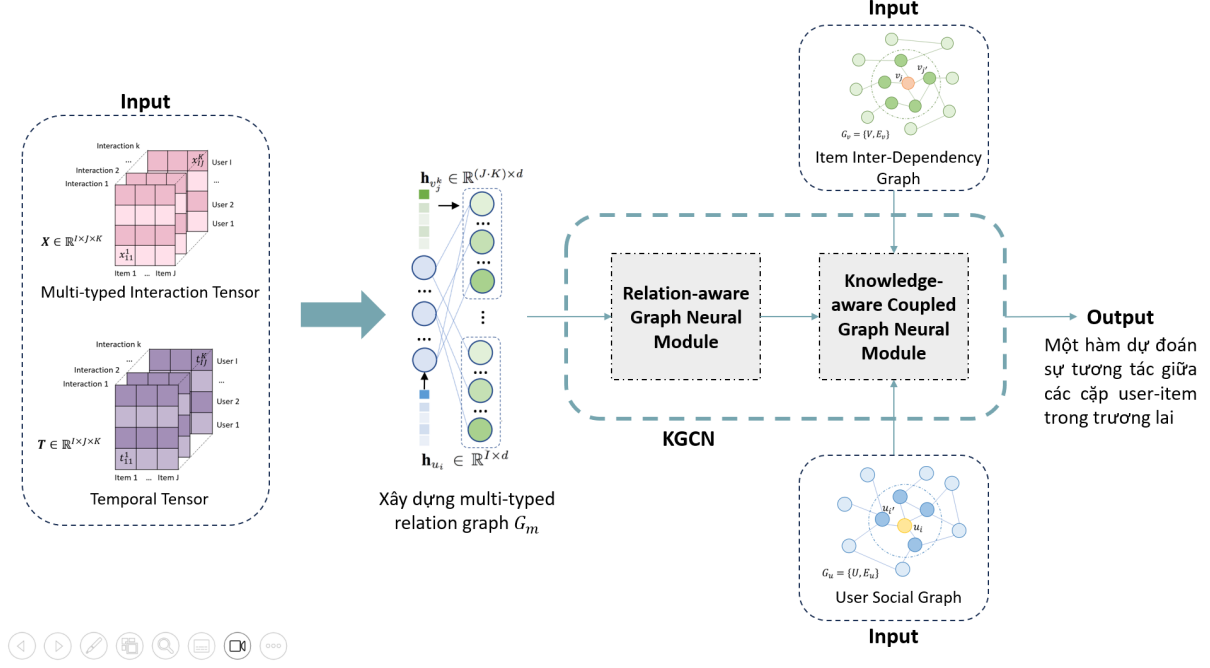


Figure 8: Kiến trúc tổng quan của mô hình KGCN

cao nhất thì có khả năng cao nhất là user sẽ tương tác tiếp theo.

Relation-aware Graph Neural Module

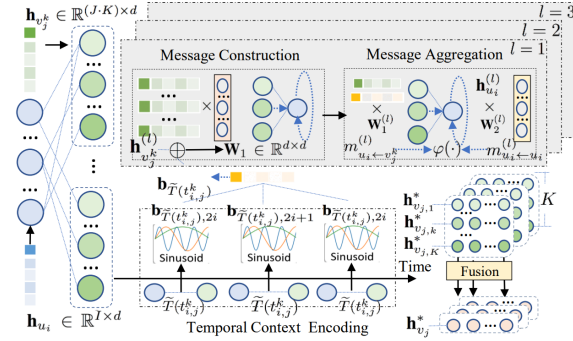


Figure 9: Tổng quan kiến trúc của Relation-aware Graph Neural Module

Kiến trúc relation-aware graph neural có tác dụng mã hóa các mối quan hệ cộng tác khác nhau giữa user-item, được xây dựng dựa trên cơ chế lan truyền message, như minh họa trong Hình 9. Từ một multi-typed interaction tensor \mathbf{X} , chúng tôi trước hết xây dựng một multi-typed relation graph G_m với tập các đỉnh con biểu diễn các loại tương tác khác nhau của user trên mỗi item $v_j \rightarrow (v_j^1, \dots, v_j^K)$, trong đó, K thể hiện số loại tương tác. Mỗi cạnh nối u_i và v_j^k đại diện cho tương tác loại k giữa user và item đó. Như vậy, đồ thị $G_m = (V_m, E_m)$ sẽ có $(I + J \cdot K)$ đỉnh, với

$V_m = U \cup V'$ và $v_j^k \in V'$. V' bây giờ là tập hợp các item có phân biệt loại tương tác (Cùng một nhà hàng, nhưng nhà hàng được rate 3 sao sẽ được coi là một item riêng biệt với cùng nhà hàng đó nhưng được đánh giá 5 sao).

Pha khởi tạo message: Trước hết, mô hình sẽ xây dựng một message giữa user u_i và item v_j^k mà user đó đã tương tác như sau:

$$\begin{aligned} m_{u_i \leftarrow v_j^k} &= \gamma(\mathbf{h}_{v_j^k}, \rho_{i,j}^k) \\ m_{v_j^k \leftarrow u_i} &= \gamma(\mathbf{h}_{u_i}, \rho_{i,j}^k) \end{aligned} \quad (4)$$

Trong đó, $\gamma(\cdot)$ là hàm mã hóa thông tin trên embeddings của đặc trưng input $\mathbf{h}_{v_j^k} \in \mathbb{R}^{(J \cdot K) \times d}$, $\mathbf{h}_{u_i} \in \mathbb{R}^{I \times d}$. $\rho_{i,j}^k$ là decay factor để chuẩn hóa sự ảnh hưởng được lan truyền theo node degrees (Chen et al., 2020). Cụ thể, $\rho = \frac{1}{\sqrt{|N_i| |N_j^k|}}$, trong đó N_i là số lượng node hàng xóm của user u_i và N_j^k thể hiện số lượng user tương tác loại k với item v_j . Do đó, công thức khởi tạo một message đầy đủ, với \mathbf{W}_1 là ma trận trọng số, là:

$$\begin{aligned} m_{u_i \leftarrow v_j^k} &= \frac{1}{\sqrt{|N_i| |N_j^k|}} (\mathbf{h}_{v_j^k} \cdot \mathbf{W}_1) \\ m_{v_j^k \leftarrow u_i} &= \frac{1}{\sqrt{|N_i| |N_j^k|}} (\mathbf{h}_{u_i} \cdot \mathbf{W}_1) \end{aligned} \quad (5)$$

Mã hóa thông tin thời gian. Lấy cảm hứng từ

các giải pháp khuyến nghị mô hình hóa thông tin thời gian (Sun et al., 2018; Huang et al., 2019), trong mô hình KGCN, nhóm tác giả cho rằng các tương tác giữa user và item xảy ra ở các thời điểm khác nhau. Bằng cách giới thiệu một cơ chế mã hóa thông tin về thời gian, KGCN sẽ có khả năng mô hình hóa được các sự phụ thuộc biến đổi theo thời gian của các loại tương tác khác nhau giữa user và item. Dựa trên thuật toán positional encoding của kiến trúc Transformer (Vaswani et al., 2017; Sun et al., 2019; Wu et al., 2020), mô hình sẽ ánh xạ timestamp ($t_{i,j}^k$) tương ứng với mỗi tương tác $x_{i,j}^k$ thành các time slot $\tilde{T}(t_{i,j}^k)$. Chúng tôi sử dụng hàm sinusoid để tạo ra các time embedding cho cạnh $e_{i,j}^k \in E_m$ của đồ thị G_m như sau:

$$\begin{aligned} \mathbf{b}_{\tilde{T}(t_{i,j}^k), 2i} &= \sin(\tilde{T}(t_{i,j}^k)/10000^{\frac{2i}{d}}) \\ \mathbf{b}_{\tilde{T}(t_{i,j}^k), 2i+1} &= \cos(\tilde{T}(t_{i,j}^k)/10000^{\frac{2i+1}{d}}) \end{aligned} \quad (6)$$

Trong đó, $(2i)$ và $(2i+1)$ lần lượt biểu diễn vị trí chẵn và lẻ trong embedding $\mathbf{b}_{\tilde{T}(t_{i,j}^k)}$.

Pha tổng hợp hợp high-order message. Mô hình sẽ tích hợp các message được lan truyền giữa user u_i và item v_j^k , cùng với bối cảnh thời gian $\mathbf{b}_{\tilde{T}(t_{i,j}^k)}$ trên cạnh $e_{i,j}^k$ vào mô hình lan truyền thông tin như sau:

$$\begin{aligned} \mathbf{h}_{u_i}^{(l+1)} &= \varphi(m_{u_i \leftarrow u_i}^{(l)} + \sum_{(j,k) \in N_{u_i}} m_{u_i \leftarrow v_j^k}^{(l)}) \\ &= \varphi\left(\frac{1}{|N_{u_i}|} \mathbf{h}_{u_i}^{(l)} \mathbf{W}_2^{(l)} + \sum_{(j,k) \in N_{u_i}} \frac{1}{|N_{v_j^k}|} (\mathbf{h}_{v_j^k}^{(l)} \oplus \mathbf{b}_{\tilde{T}(t_{i,j}^k)}) \mathbf{W}_1^{(l)}\right) \end{aligned} \quad (7)$$

Trong đó, $\varphi(\cdot)$ là hàm LeakyReLU, $m_{u_i \leftarrow u_i}^{(l)}$ là message tự lan truyền với ma trận trọng số $\mathbf{W}_2^{(l)} \in \mathbb{R}^{d \times d}$, \oplus là phép cộng element-wise, và l là index của L graph layers. Cuối cùng, mô hình sẽ cho ra user embeddings $\mathbf{h}_{u_i}^*$ và item embeddings $\mathbf{h}_{v_j^k}^*$ với toán tử ghép nối \parallel như sau:

$$\begin{aligned} \mathbf{h}_{u_i}^* &= (\mathbf{h}_{u_i}^{(0)} \parallel \mathbf{h}_{u_i}^{(1)} \parallel \dots \parallel \mathbf{h}_{u_i}^{(L)}) \\ \mathbf{h}_{v_j^k}^* &= (\mathbf{h}_{v_j^k}^{(0)} \parallel \mathbf{h}_{v_j^k}^{(1)} \parallel \dots \parallel \mathbf{h}_{v_j^k}^{(L)}) \end{aligned} \quad (8)$$

Chúng tôi tóm tắt biểu diễn của mỗi item v_j^k thành dạng $\mathbf{h}_{v_j^k}^*$ trên tất cả embeddings của các đỉnh

con $\mathbf{h}_{v_j^k}^*$, ($k \in [1, \dots, K]$) bằng cơ chế gating (Ma et al., 2019) để phân biệt tầm quan trọng của các kiểu mẫu tương tác được phân loại.

Knowledge-aware Coupled Graph Neural Module

Để cùng đưa thông tin về sự phụ thuộc lẫn nhau giữa user-user và item-item vào mô hình, nhóm tác giả phát triển một knowledge-aware coupled graph neural network cho phép cộng tác giữa mô hình biểu diễn đồ thị và học thông tin lẫn nhau. Mặc dù đã có nhiều nghiên cứu tập trung mô hình hóa thông tin cấu trúc biểu đồ, nhưng chúng bị hạn chế về khả năng nắm bắt cả cấu trúc biểu đồ cục bộ và toàn cục (Veličković et al., 2018). KGCN được trang bị mô hình học đồ thị hai giai đoạn (Như trong Hình 10).

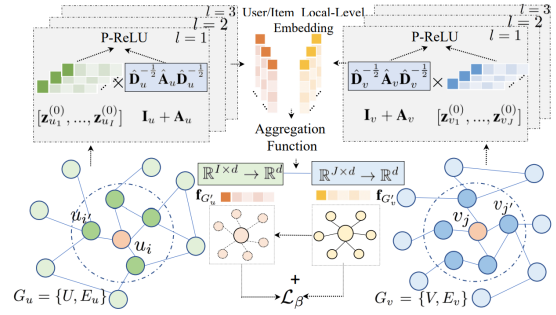


Figure 10: Tổng quan kiến trúc của Knowledge-aware Graph Neural Module

Mô hình hóa các cấu trúc quan hệ cục bộ. Mô hình trước hết sẽ học các embedding cho từng user \mathbf{z}_{u_i} và item \mathbf{z}_{v_j} . Các embedding này biểu diễn các thông tin kết nối cục bộ trên user social graph G_u và item inter-dependent graph G_v . Các embedding này sẽ được cập nhật và lan truyền qua mỗi layer bởi công thức sau:

$$\begin{aligned} [\mathbf{z}_{u_1}^{(l+1)}, \dots, \mathbf{z}_{u_I}^{(l+1)}] &= \varphi([\mathbf{z}_{u_1}^{(l)}, \dots, \mathbf{z}_{u_I}^{(l)}] \cdot \eta(G_u)) \\ [\mathbf{z}_{v_1}^{(l+1)}, \dots, \mathbf{z}_{v_J}^{(l+1)}] &= \varphi([\mathbf{z}_{v_1}^{(l)}, \dots, \mathbf{z}_{v_J}^{(l)}] \cdot \eta(G_v)) \end{aligned} \quad (9)$$

Trong đó, $\mathbf{z}_{u_i}^0 = \mathbf{h}_{u_i}^*$, $\mathbf{z}_{v_j}^0 = \mathbf{h}_{v_j}^*$, $\eta(G_v) = \hat{\mathbf{D}}_v^{-\frac{1}{2}} \hat{\mathbf{A}}_v \hat{\mathbf{D}}_v^{-\frac{1}{2}}$, $\eta(G_u) = \hat{\mathbf{D}}_u^{-\frac{1}{2}} \hat{\mathbf{A}}_u \hat{\mathbf{D}}_u^{-\frac{1}{2}}$ với $\hat{\mathbf{A}}_v$ là tổng của ma trận đơn vị \mathbf{I}_v và ma trận kề \mathbf{A}_v , $\hat{\mathbf{A}}_u$ là tổng của ma trận đơn vị \mathbf{I}_u và ma trận kề \mathbf{A}_u .

Trong mô hình KGCN, nhóm tác giả mong muốn tích hợp cả cấu trúc quan hệ cấp cục bộ và cấp toàn cục vào user social graph và item inter-dependent graph vào các user và item embedding đã học phía

trên. Do đó, họ làm phong phú thêm bối cảnh toàn cục bằng cách xem xét các đồ thị con (Ví dụ: một user social graph của tất cả user có thể bao gồm nhiều đồ thị con G'_u khác nhau). Cụ thể hơn, một biểu diễn cặp đồ thị hợp nhất $\mathbf{f}_{G'_u}, \mathbf{f}_{G'_v} \in \mathbb{R}^d$ được tạo ra bằng cách áp dụng mean pooling trên các node-specific embeddings.

Để ước lượng sự phụ thuộc lẫn nhau giữa các cặp node và đồ thị, các mẫu dương tính $(\mathbf{z}_{u_i}, \mathbf{f}_{G'_u}), (\mathbf{z}_{v_j}, \mathbf{f}_{G'_v})$ và mẫu âm tính $(\tilde{\mathbf{z}}_{u_i}, \mathbf{f}_{G'_u}), (\tilde{\mathbf{z}}_{v_j}, \mathbf{f}_{G'_v})$ được tạo ra, trong đó $\tilde{\mathbf{z}}_{u_i}$ và $\tilde{\mathbf{z}}_{v_j}$ được chọn một cách ngẫu nhiên. Bằng cách này, ta sẽ tạo ra các mối quan hệ theo cặp node-graph bị đặt sai vị trí. Sau đó, nhóm tác giả định nghĩa một hàm noise-contrastive knowledge-aware loss \mathcal{L}_β như sau:

$$\begin{aligned} \mathcal{L}_\beta = & -\frac{\lambda_1}{N_{pos}^u + N_{neg}^u} \left(\sum_{i=1}^{N_{pos}^u} \tau(\mathbf{z}_{u_i}, \mathbf{f}_{G'_u}) \cdot \log \sigma(\mathbf{z}_{u_i} \cdot \mathbf{f}_{G'_u}) \right) \\ & + \sum_{i=1}^{N_{neg}^u} \tau(\tilde{\mathbf{z}}_{u_i}, \mathbf{f}_{G'_u}) \cdot \log[1 - \sigma(\tilde{\mathbf{z}}_{u_i} \cdot \mathbf{f}_{G'_u})] \\ & -\frac{\lambda_2}{N_{pos}^v + N_{neg}^v} \left(\sum_{j=1}^{N_{pos}^v} \tau(\mathbf{z}_{v_j}, \mathbf{f}_{G'_v}) \cdot \log \sigma(\mathbf{z}_{v_j} \cdot \mathbf{f}_{G'_v}) \right) \\ & + \sum_{j=1}^{N_{neg}^v} \tau(\tilde{\mathbf{z}}_{v_j}, \mathbf{f}_{G'_v}) \cdot \log[1 - \sigma(\tilde{\mathbf{z}}_{v_j} \cdot \mathbf{f}_{G'_v})] \end{aligned} \quad (10)$$

Trong đó, N_{pos}^u/N_{neg}^u và N_{pos}^v/N_{neg}^v lần lượt là số lượng mẫu dương tính và âm tính được chọn trên sub-graph G'_u và G'_v . $\tau(\cdot)$ là một hàm chỉ định. Chẳng hạn, $\tau(\mathbf{z}_{u_i}, \mathbf{f}_{G'_u}) = 1$ thì nghĩa là hàm loss đang tính toán trên cặp mẫu dương tính, còn $\tau(\tilde{\mathbf{z}}_{u_i}, \mathbf{f}_{G'_u}) = 1$ thì tức là hàm loss đang tính toán trên cặp mẫu âm tính. λ_1 và λ_2 là tham số cân bằng. Mục tiêu của mô hình là giảm thiểu \mathcal{L}_β , tức là tối ưu sự phụ thuộc thông tin lẫn nhau giữa các cặp node-graph ở mức độ toàn cục, vừa bảo tồn đặc điểm riêng biệt của mỗi user và item.

Tối ưu hóa mô hình

Để mô hình học các tham số huấn luyện, nhóm tác giả đã tích hợp hàm loss BPR (Bayesian Personalized Ranking) theo cặp (Rendle et al., 2012), đã được sử dụng rộng rãi trong các nghiên cứu về hệ khuyến nghị (Wang et al., 2019d). BPR giả định rằng các tương tác giữa user và item đã được quan

sát (positive samples), phản ánh nhiều hơn về sở thích của user, nên được chỉ định giá trị dự đoán cao hơn những tương tác chưa được quan sát (negative samples). Tóm lại, hàm loss được định nghĩa như sau:

$$\begin{aligned} \mathcal{L} = & \sum_{(i,j^+,j^-) \in O} -\ln \sigma(\hat{x}_{i,j^+} - \hat{x}_{i,j^-}) \\ & + \lambda \|\Theta\|^2 + \mathcal{L}_\beta \end{aligned} \quad (11)$$

Trong công thức trên, dữ liệu huấn luyện theo cặp được kí hiệu là $O = \{(u, j^+, j^-) | (u, j^+) \in \mathcal{R}^+, (u, j^-) \in \mathcal{R}^-\}$, với $(\mathcal{R}^+, \mathcal{R}^-)$ lần lượt là các tương tác đã được quan sát và chưa được quan sát. $\hat{x}_{i,j}$ là kết quả của phép nhân vô hướng giữa embedding của u_i và v_j . Θ là các tham số huấn luyện, $\sigma(\cdot)$ là hàm kích hoạt sigmoid, λ giúp kiểm soát L2 regularization để tránh cho mô hình bị overfitting.

Chi tiết về cài đặt mô hình và tham số huấn luyện

Mô hình được cài đặt trên framework Pytorch và sử dụng optimizer Adam để ước lượng siêu tham số. Quá trình huấn luyện được thực hiện trong 180 epoch, với learning rate là 0.01, batch size là 2048, kích thước embedding là 64 và 64 layer GCN. Đối với quá trình đánh giá mô hình, kỹ thuật dừng sớm được áp dụng nếu loss trên tập validation không giảm sau 5 epoch liên tiếp.

5 Phân tích kết quả

5.1 Kết quả khuyến nghị

Giá trị độ đo HR và NDCG ở vị trí thứ 10 của 3 phương pháp khuyến nghị được thể hiện ở Bảng 3. Ta có thể thấy mô hình KGCN có kết quả tốt vượt trội so với 2 phương pháp truyền thống là Item-based collaborative filtering và content-based. Giá trị HR@10 lên tới khoảng 77% và NDCG@10 có giá trị khoảng 50%. Điều này là dễ hiểu vì mô hình KGCN biểu diễn dữ liệu dưới dạng đồ thị, có khả năng mô hình hóa và rút trích được các mối quan hệ phụ thuộc phức tạp biến động theo thời gian giữa các user-item, item-item và user-user.

Trong khi đó, hai phương pháp truyền thống thực hiện đề xuất nhà hàng với cơ chế rất đơn giản. Nó chỉ lấy ngẫu nhiên 1 nhà hàng được đánh giá cao nhất trong chuỗi hành vi lịch sử làm đại diện cho sở thích của người dùng và đề xuất các nhà hàng tương tự với sở thích đó. Cách lấy ngẫu nhiên này chưa có khả năng tổng quát hóa sở thích của người

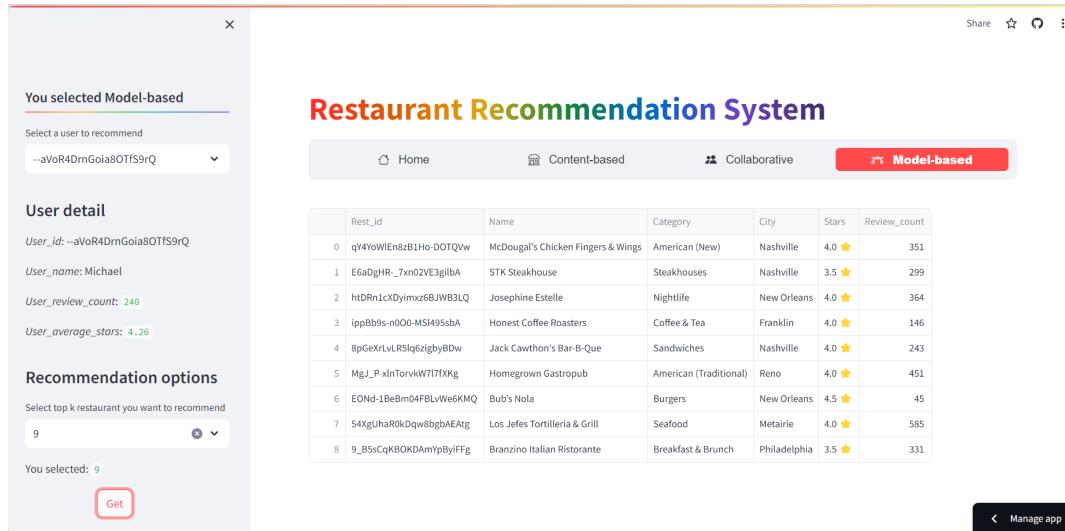


Figure 11: Demo web app cho Yelp Restaurant Recommender System

dùng nên kết quả dự đoán của 2 phương pháp này còn hạn chế và cho ra kết quả rất thấp. Giá trị $HR@10$ lần lượt là 0.00291 và 0.00097 cho item-based collaborative filtering và content-based, tức là 2 phương pháp này chỉ đưa ra đề xuất đúng cho 18 và 6 user trên tổng số khoảng 6000 user.

	HR@10	NDCG@10
Item-based CF	0.00291	0.00229
Content based	0.00097	0.00064
KGCN	0.77206	0.50678

Table 3: Kết quả khuyến nghị của 3 phương pháp item-based collaborative filtering, content-based và KGCN

Nhóm cũng tiến hành so sánh kết quả trên mô hình KGCN tự cài đặt với kết quả được đưa ra ở bài báo gốc (Huang et al., 2021). Trong cài đặt gốc, nhóm tác giả thực nghiệm trên bộ dữ liệu Yelp có khoảng 40000 user, 60000 item và 300000 tương tác, có kích thước lớn hơn khoảng 10 lần bộ dữ liệu của nhóm (Bảng 2).

	HR@10	NDCG@10
Original Paper	0.803	0.530
Our results	0.772	0.507

Table 4: So sánh kết quả của đề án với kết quả trong bài báo gốc (Huang et al., 2021)

Tuy có sự chênh lệch lớn về kích thước tập dữ liệu nhưng kết quả nhóm đạt được không quá chênh lệch so với bài báo gốc, chỉ thấp hơn khoảng 3% trên cả 2 độ đo (như quan sát ở Bảng 4). Điều này chứng tỏ mô hình KGCN đưa ra đề xuất tốt trên bộ

dữ liệu có kích thước vừa và nhỏ.

5.2 Kết quả demo

Để mô phỏng hệ thống khuyến nghị nhóm sử dụng Streamlit để xây dựng một web app có khả năng đề xuất cho người dùng một danh sách các nhà hàng theo từng phương pháp như minh họa Hình 11. Nhóm giả sử chọn "user_id" để chọn người dùng muốn đề xuất, thông tin về người dùng sẽ được chú thích. Bên cạnh đó người dùng có thể chọn top k giá trị muốn khuyến nghị.

6 Kết luận

Tóm lại, trong phạm vi đề án, nhóm đã giải quyết bài toán khuyến nghị nhà hàng dưới dạng bài toán dự đoán item tuần tự. Nhóm đã sử dụng một phần nhỏ bộ dữ liệu Yelp để phục vụ cho bài toán. Nhóm giải quyết bài toán sử dụng 3 phương pháp khác nhau: Collaborative Filtering (Item-based), Content-based và Knowledge-based (mô hình Knowledge-aware Coupled Graph Neural Networks - KGCN). Kết quả thu được tốt nhất là trên mô hình KGCN, với giá trị $HR@10$ khoảng 77% và $NDCG@10$ khoảng 50%. Phương pháp Item-based Collaborative Filtering và Content-based đều không đủ khả năng tổng quát hóa sở thích của người dùng nên kết quả khuyến nghị rất thấp. Nhóm cũng đã thực hiện demo kết quả khuyến nghị của 3 phương pháp trên sử dụng thư viện Streamlit. So với bài báo gốc của tác giả thì lượng dữ liệu hiện tại khá nhỏ, do đó để nâng cao hiệu quả mô hình trong tương lai nhóm có thể sẽ tăng số lượng dữ liệu hoặc mở rộng phạm vi dữ liệu ra các lĩnh vực khác ngoài nhà hàng.

References

- Syed M. Ali, Gopal K. Nayak, Rakesh K. Lenka, and Rabindra K. Barik. 2018. Movie recommendation system using genome tags and content-based filtering. In *Advances in Data and Information Sciences*, pages 85–94, Singapore. Springer Singapore.
- Elham Asani, Hamed Vahdat-Nejad, and Javad Sadri. 2021. [Restaurant recommender system based on sentiment analysis](#). *Machine Learning with Applications*, 6:100114.
- Ana Belén Barragáns-Martínez, Enrique Costa-Montenegro, Juan C. Burguillo, Marta Rey-López, Fernando A. Mikic-Fonte, and Ana Peleteiro. 2010. [A hybrid content-based and item-based collaborative filtering approach to recommend tv programs enhanced with singular value decomposition](#). *Information Sciences*, 180(22):4290–4311.
- J. Bobadilla, F. Ortega, A. Hernando, and A. Gutiérrez. 2013. [Recommender systems survey](#). *Knowledge-Based Systems*, 46:109–132.
- Yixin Cao, Xiang Wang, Xiangnan He, Zikun Hu, and Tat-Seng Chua. 2019. [Unifying knowledge graph learning and recommendation: Towards a better understanding of user preferences](#). In *The World Wide Web Conference, WWW '19*, page 151–161, New York, NY, USA. Association for Computing Machinery.
- Jose Jesus Castro-Schez, Raul Miguel, David Vallejo, and Lorenzo Manuel López-López. 2011. [A highly adaptive recommender system based on fuzzy logic for b2c e-commerce portals](#). *Expert Systems with Applications*, 38(3):2441–2454.
- Lei Chen, Le Wu, Richang Hong, Kun Zhang, and Meng Wang. 2020. [Revisiting graph based collaborative filtering: A linear residual graph convolutional network approach](#). *CoRR*, abs/2001.10167.
- Min Gao, Kecheng Liu, and Zhongfu Wu. 2010. Personalisation in web computing and informatics: Theories, techniques, applications, and future research. *Information Systems Frontiers*, 12:607–629.
- Michelle Hartanto and Ditdit Nugeraha Utama. 2020. [Intelligent decision support model for recommending restaurant](#). *Cogent Engineering*, 7(1):1763888.
- Chao Huang, Xian Wu, Xuchao Zhang, Chuxu Zhang, Jiashu Zhao, Dawei Yin, and Nitesh V. Chawla. 2019. [Online purchase prediction via multi-scale modeling of behavior dynamics](#). In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD '19*, page 2613–2622, New York, NY, USA. Association for Computing Machinery.
- Chao Huang, Huance Xu, Yong Xu, Peng Dai, Lianghao Xia, Mengyin Lu, Liefeng Bo, Hao Xing, Xiaoping Lai, and Yanfang Ye. 2021. [Knowledge-aware coupled graph neural network for social recommendation](#). *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(5):4115–4122.
- Zan Huang, Daniel Zeng, and Hsinchun Chen. 2007. A comparison of collaborative-filtering recommendation algorithms for e-commerce. *IEEE Intelligent Systems*, 22(5):68–78.
- Wang-Cheng Kang and Julian McAuley. 2018. [Self-attentive sequential recommendation](#). In *2018 IEEE International Conference on Data Mining (ICDM)*, pages 197–206.
- Yehuda Koren. 2008. [Factorization meets the neighborhood: A multifaceted collaborative filtering model](#). In *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '08*, page 426–434, New York, NY, USA. Association for Computing Machinery.
- Ngoc Luyen Le, Marie-Hélène Abel, and Philippe Gouspillou. 2023. A personalized recommender system based-on knowledge graph embeddings. In *The 3rd International Conference on Artificial Intelligence and Computer Vision (AICV2023), March 5–7, 2023*, pages 368–378, Cham. Springer Nature Switzerland.
- Seok Kee Lee, Yoon Ho Cho, and Soung Hie Kim. 2010. [Collaborative filtering with ordinal scale-based implicit ratings for mobile music recommendations](#). *Information Sciences*, 180(11):2142–2155.
- Yang Li, Kangbo Liu, Ranjan Satapathy, Suhang Wang, and Erik Cambria. 2023. [Recent developments in recommender systems: A survey](#).
- Chen Ma, Peng Kang, and Xue Liu. 2019. [Hierarchical gating networks for sequential recommendation](#). *CoRR*, abs/1906.09217.
- Alexandros Nanopoulos, Dimitrios Rafailidis, Panagiotis Symeonidis, and Yannis Manolopoulos. 2010. [Musicbox: Personalized music recommendation based on cubic analysis of social tags](#). *IEEE Transactions on Audio, Speech, and Language Processing*, 18(2):407–412.
- Deuk Hee Park, Hyea Kyeong Kim, Il Young Choi, and Jae Kyeong Kim. 2012. [A literature review and classification of recommender systems research](#). *Expert Systems with Applications*, 39(11):10059–10072.
- Moon-Hee Park, Han-Saem Park, and Sung-Bae Cho. 2008. Restaurant recommendation for group of people in mobile environments using probabilistic multi-criteria decision making. In *Computer-Human Interaction*, pages 114–122, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. 2012. [BPR: bayesian personalized ranking from implicit feedback](#). *CoRR*, abs/1205.2618.

- Arup Roy, Soumya Banerjee, Manash Sarkar, Ashraf Darwish, Mohamed Elhoseny, and Aboul Ella Hassanien. 2018. [Exploring new vista of intelligent collaborative filtering: A restaurant recommendation paradigm](#). *Journal of Computational Science*, 27:168–182.
- Guy Shani and Asela Gunawardana. 2011. *Evaluating Recommendation Systems*, pages 257–297. Springer US, Boston, MA.
- Mugdha Sharma, Laxmi Ahuja, and Vinay Kumar. 2021. Study and classification of recommender systems: A survey. In *International Conference on Innovative Computing and Communications*, pages 1153–1163, Singapore. Springer Singapore.
- Jieun Son and Seoung Bum Kim. 2017. [Content-based filtering for recommendation systems using multiattribute networks](#). *Expert Systems with Applications*, 89:404–412.
- Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. 2019. [Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer](#). In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management, CIKM '19*, page 1441–1450, New York, NY, USA. Association for Computing Machinery.
- Peijie Sun, Le Wu, and Meng Wang. 2018. [Attentive recurrent social recommendation](#). In *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval, SIGIR '18*, page 185–194, New York, NY, USA. Association for Computing Machinery.
- Shulong Tan, Jiajun Bu, Chun Chen, Bin Xu, Can Wang, and Xiaofei He. 2011. [Using rich social media information for music recommendation via hypergraph model](#). *ACM Trans. Multimedia Comput. Commun. Appl.*, 7S(1).
- Marco Vanetti, Elisabetta Binaghi, Barbara Carminati, Moreno Carullo, and Elena Ferrari. 2011. Content-based filtering in on-line social networks. In *Privacy and Security Issues in Data Mining and Machine Learning*, pages 127–140, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. [Attention is all you need](#). *CoRR*, abs/1706.03762.
- Petar Veličković, William Fedus, William L. Hamilton, Pietro Liò, Yoshua Bengio, and R Devon Hjelm. 2018. [Deep graph infomax](#).
- Hongwei Wang, Fuzheng Zhang, Mengdi Zhang, Jure Leskovec, Miao Zhao, Wenjie Li, and Zhongyuan Wang. 2019a. [Knowledge-aware graph neural networks with label smoothness regularization for recommender systems](#). In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD '19*, page 968–977, New York, NY, USA. Association for Computing Machinery.
- Hongwei Wang, Fuzheng Zhang, Miao Zhao, Wenjie Li, Xing Xie, and Minyi Guo. 2019b. [Multi-task feature learning for knowledge graph enhanced recommendation](#). In *The World Wide Web Conference, WWW '19*, page 2000–2010, New York, NY, USA. Association for Computing Machinery.
- Xiang Wang, Xiangnan He, Yixin Cao, Meng Liu, and Tat-Seng Chua. 2019c. [Kgat: Knowledge graph attention network for recommendation](#). In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD '19*, page 950–958, New York, NY, USA. Association for Computing Machinery.
- Xiang Wang, Xiangnan He, Meng Wang, Fuli Feng, and Tat-Seng Chua. 2019d. [Neural graph collaborative filtering](#). In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR '19*, page 165–174, New York, NY, USA. Association for Computing Machinery.
- Xian Wu, Chao Huang, Chuxu Zhang, and Nitesh V. Chawla. 2020. [Hierarchically structured transformer networks for fine-grained spatial event forecasting](#). In *Proceedings of The Web Conference 2020, WWW '20*, page 2320–2330, New York, NY, USA. Association for Computing Machinery.
- Zonghan Wu, Shirui Pan, Fengwen Chen, Guodong Long, Chengqi Zhang, and Philip S. Yu. 2021. [A comprehensive survey on graph neural networks](#). *IEEE Transactions on Neural Networks and Learning Systems*, 32(1):4–24.
- Zhiwen Yu, Xingshe Zhou, Yanbin Hao, and Jianhua Gu. 2006. [Tv program recommendation for multiple viewers based on user profile merging](#). *User Modeling and User-Adapted Interaction*, 16(1):63–82.
- Kun Zhou, Wayne Xin Zhao, Shuqing Bian, Yuanhang Zhou, Ji-Rong Wen, and Jingsong Yu. 2020. [Improving conversational recommender systems via knowledge graph based semantic fusion](#). In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, KDD '20*, page 1006–1014, New York, NY, USA. Association for Computing Machinery.